

# Incertidumbre 3: Razonamiento Probabilístico

# Representación Numérica de la Incertidumbre: Probabilidad

- **La Teoría de la Probabilidad (TProb)**

- Es un área de las Matemáticas que ha sido aplicada a problemas de razonamiento con incertidumbre
- Es una **teoría elegante, bien entendida y con mucha historia** (formalizaciones a partir de mediados del siglo XVII)
- Asigna **valores numéricos** (llamados probabilidades) a las proposiciones.
- Nos dice, dadas las probabilidades de ciertas proposiciones, y algunas relaciones entre ellas como asignar probabilidades a las proposiciones relacionadas
- Relación con la LPO:
  - En la LPO las proposiciones son ciertas o falsas.
  - Con la Tprob las proposiciones son también ciertas o falsas pero se tiene un grado de creencia en la certeza o falsedad.

# ¿Qué son las Probabilidades?

- **A pesar de su larga historia los valores numéricos que representan las probabilidad no tiene una interpretación única.**
- **Algunas Interpretaciones:**
  - **Frecuentista:** Es el valor, cuando el número de pruebas tiende a infinito, de la frecuencia de que ocurra algún evento
  - **Subjetiva:** Es un grado de creencia acerca de un evento incierto
- **Aún así:**
  - Existe un consenso sobre el modelo matemático que soporta la Teoría

# Los Valores Numéricos de la Probabilidad

- **Denotaremos por  $P(A)$  a la probabilidad de la proposición  $A$** 
  - $A = \text{"El paciente tiene sarampión"}$
  - $A = \text{"Mañana saldrá el sol"} \dots$
- **Los valores de la Probabilidad satisfacen un conjunto de **axiomas**:**
  - $0 \leq P(A) \leq 1$
  - $P(\text{Proposición Verdadera}) = 1$
  - $P(A \vee B) = P(A) + P(B)$ 
    - Siempre que  $A$  y  $B$  sean disjuntos, es decir  $\neg(A \wedge B)$
- **A partir de ellos se puede demostrar por ejemplo:**
  - $P(\neg A) = 1 - P(A)$
  - $P(\text{Proposición Falsa}) = 0$
  - $P(A \vee B) = P(A) + P(B) - P(A \wedge B)$

# Variables Aleatorias

- **Muchas veces tenemos un evento con un conjunto de resultados:**

- **Completo**

- Se conocen **todos** los posibles resultados

- **Mutuamente excluyente**

- No se pueden dar dos resultados distintos **simultáneamente**.

## Ejemplos

- Si tiramos una moneda, el resultado es cara o cruz
  - Si tiramos un dado, se producen seis resultados distintos
  - La temperatura de un paciente puede estar en un conjunto de intervalos:  $<36.5$ ,  $36.5-37.4$ ,  $37.5-38.4$ ,  $38.5-39.4$ ,  $>39.4$
- **En lugar de tener una proposición para cada resultado se introduce el concepto de **Variable aleatoria****
- **Se permiten proposiciones de la forma **Variable = resultado****
  - Por ejemplo, si  $M$ ="Resultado de tirar una moneda con valores posibles cara y cruz" se permiten las proposiciones:
    - $M=\text{cara}$  y  $M=\text{Cruz}$  y podemos hablar de
    - $P(M=\text{cara})$  y  $P(M=\text{cruz})$  que representan la probabilidad de obtener una cara y una cruz respectivamente

# Variables Aleatorias

- **Por consistencia, se puede considerar que **todas las proposiciones son variables aleatorias** que toman dos valores verdadero o falso**
  - Por ejemplo, dada la proposición “Tiene Sarampión”
    - Construimos la variable aleatoria Sarampión que toma los valores verdadero y falso
  - Y representamos la probabilidad de que un paciente tenga Sarampión  $P(\text{“Tiene Sarampión”})$  como  $P(\text{Sarampión} = \text{verdadero})$
- **Abreviaturas**
  - Se suele escribir  $P(M = \text{cara})$  como  $P(\text{cara})$ , cuando está claro que nos referimos a la variable aleatoria  $M$ .
  - Si una variable aleatoria como Sarampión toma únicamente los valores verdadero o falso se suele escribir  $P(\text{Sarampión} = \text{verdadero})$  como  $P(\text{sarampión})$  y  $P(\text{Sarampión} = \text{falso})$  como  $P(\neg \text{sarampión})$

# Distribuciones de Probabilidad

- Dada una **Variable Aleatoria** nos gustaría conocer la probabilidad para **cada** valor que pueda tomar
- Esta descripción se llama **distribución de probabilidad** (Dprob) de la variable aleatoria y consiste en listar los valores de probabilidad para cada valor de la variable
- **Ejemplo:**
  - Distribución de probabilidad de la variable Llueve

Variable	→	Llueve	P(Llueve)	
		Verdadero	0.1	
Valores	↙ ↘	Falso	0.9	↔ Probabilidades

# Proposiciones más Complejas

- **Podemos estar interesados en estudiar varias variables en conjunto.**
  - Por ejemplo
    - $P(\text{Sarampión}=\text{verdadero} \wedge \text{Fiebre}=\text{verdadero})$  que es la probabilidad de que el paciente tenga sarampión y fiebre
  - Generalmente lo escribiremos como:
    - $P(\text{sarampión} \wedge \text{fiebre})$  o  $P(\text{sarampión}, \text{fiebre})$
- **Para ello se necesita asignar probabilidades a cada posible combinación de los valores de las variables.**
- **El listado de todos esos valores se llama la distribución conjunta del conjunto de variables**



# Ejemplo de distribución conjunta

- **Distribución conjunta** de las variables **Llueve** y **EnCalle**  
 **$P(\text{Llueve}, \text{EnCalle})$ :**

Llueve	EnCalle	$P(\text{Llueve}, \text{EnCalle})$
Verdadero	Verdadero	0.01
Verdadero	Falso	0.09
Falso	Verdadero	0.2
Falso	Falso	0.7

- **También se puede escribir como:**

Llueve	EnCalle	$P(\text{Llueve}, \text{EnCalle})$
llueve	encalle	0.01
llueve	$\neg$ encalle	0.09
$\neg$ llueve	encalle	0.2
$\neg$ llueve	$\neg$ encalle	0.7

- **Recuerda a la tabla de la verdad lógica excepto que:**
  - Describe las probabilidad para cada combinación de valores de las variables
  - Generalmente dichos valores no se pueden calcular a partir de sus componentes

# La Importancia de la Distribución Conjunta


- La distribución conjunta contiene **todo lo que se necesita saber acerca** de un conjunto de variables aleatorias.
- En particular, la distribución de cada variable individual se puede calcular a partir de la distribución conjunta (y se llama **distribución marginal**)
  - Ejemplo: Supongamos las variables aleatorias: Llueve y EnCalle con distribución conjunta  $P(\text{Llueve}, \text{EnCalle})$

llueve	encalle	0.01
llueve	¬encalle	0.09
¬ llueve	encalle	0.2
¬ llueve	¬encalle	0.7

- Entonces  $P(\text{llueve}) = P(\text{llueve} \wedge \text{enCalle}) + P(\text{llueve} \wedge \neg \text{enCalle}) = 0.01 + 0.09 = 0.1$ .
- De forma similar  $P(\neg \text{llueve}) = 0.9$
- También podemos calcular la probabilidad de disyunciones:  
 $P(\text{llueve} \vee \text{enCalle}) = 0.01 + 0.09 + 0.2 = 0.3$

# Probabilidad Condicional

- Escribiremos  $P(A|B)$  para representar la probabilidad de A dado B. Esta probabilidad se llama **probabilidad condicional**.
- Lo podemos interpretar como **mi grado de creencia en A cuando todo lo que sé es B**.
  - O de forma alternativa, de los casos en los que se da B, ¿en que proporción se da A?



Probabilidad Condicional  
Representación gráfica

- **Se define como:**
  - $P(A|B) = P(A \cap B) / P(B)$  (Asumiendo  $P(B) \neq 0$ ) o equivalentemente
  - $P(A \cap B) = P(A|B)P(B)$  (Regla del Producto)

# Distribución Condicional

- **Nos permite conocer la probabilidad de que se tomen unos determinados valores por un conjunto de variables aleatorias cuando se saben los valores que han tomado otras.**

- Ejemplo:  $P(\text{Llueve}|\text{enCalle})$

Llueve	$P(\text{Llueve} \text{enCalle})$
!lueve	0.05
$\neg$ !lueve	0.95

- Ejemplo:  $P(\text{Llueve}|\neg \text{enCalle})$


Llueve	$P(\text{Llueve} \neg \text{enCalle})$
!lueve	0.11
$\neg$ !lueve	0.89

- Nótese que  $\text{Llueve}|\text{enCalle}$  y  $\text{Llueve}|\neg \text{enCalle}$  son variables aleatorias

# Razonamiento con Probabilidades: La Regla de Bayes

- **Propuesta en 1763 por el Reverendo T. Bayes**

- $P(A|B) = P(B|A) P(A) / P(B)$
- Es una consecuencia de la regla del producto:
  - $P(A|B)P(B) = P(A,B) = P(B|A)P(A)$



Thomas Bayes

- **De forma intuitiva:**

- La probabilidad de una hipótesis A dada una evidencia B:  $P(A|B)$  es proporcional a probabilidad de la hipótesis  $P(A)$  multiplicada por el grado en que la hipótesis predice los datos  $P(B|A)$

- **Aplicabilidad**

- En muchos problemas dado un conjunto de datos (evidencia) B tenemos que seleccionar la hipótesis A más probable mediante  $P(A|B)$

# Regla de Bayes: Forma General

- **Forma general de la Regla de Bayes**

- Si se tiene un conjunto de proposiciones  $\{A_1, A_2, \dots, A_m\}$  completas y mutuamente excluyente se tiene:

$$P(A_i|B) = \frac{P(B|A_i) P(A_i)}{P(B|A_1) P(A_1) + \dots + P(B|A_n) P(A_m)}$$

O lo que es lo mismo, si tiene una variable aleatoria  $A$  con valores  $a_1, a_2, \dots, a_m$

$$P(a_i|B) = \frac{P(B|a_i) P(a_i)}{P(B|a_1) P(a_1) + \dots + P(B|a_n) P(a_m)}$$



# La Regla de Bayes: Ejemplo

- **Intentemos resolver un caso real con probabilidades:**

- Se pretende determinar la presencia o no de una enfermedad con un test.
  - En este caso:
    - Hipótesis (A): Enfermedad (variable aleatoria con dos valores verdadero y falso)
    - Evidencia (B): Test (variable aleatoria con dos valores positivo y negativo)
  - Se tiene:
    - $P(a)=1/10000$  (Prevalencia)
    - $P(b|a)=0.99$  (Sensibilidad)
    - $P(\neg b | \neg a)=0.99$  (Especificidad)
  - Aplicando la Regla de Bayes:
$$P(a|b) = \frac{P(b|a) P(a)}{P(b|a) P(a) + P(b | \neg a) P(\neg a)} = \frac{0.99 \times 0.0001}{0.99 \times 0.0001 + (1-0.99) \times (1-0.0001)} = \frac{1}{102} = 0.0098$$
$$P(\neg a | b) = 1 - 0.0098 = 0.9902$$
  - Al elegir la hipótesis más probable debemos concluir que con este test si el resultado es positivo lo más probable es que el paciente no esté enfermo!

# La Regla de Bayes: Ejemplo

- **Continuamos con el ejemplo:**

- ¿Y si hay varios tests  $B_1, B_2, \dots, B_m$ ?
  - Supondremos que cada test  $B_1, B_2, \dots, B_m$  es una variable aleatoria con dos resultados: positivo y negativo.
- Entonces si queremos calcular la probabilidad de que el paciente esté enfermo necesitamos calcular:

$$P(A | B_1, B_2, \dots, B_m) = P(B_1, B_2, \dots, B_m | A) P(A) / P(B_1, B_2, \dots, B_m)$$

- Si al paciente se le hace un conjunto de 30 pruebas y por simplificar se supone que cada una da como resultado sí o no.
  - Entonces para almacenar la tabla de probabilidad conjunta  $P(B_1, B_2, \dots, B_m | A)$  se necesitan guardar unos  $2^{30}$  números reales (unos 8 DVD's por paciente).
  - ¿De donde sacamos los números? ¿Cómo estimar los números a partir de casos (en la Tierra hay  $2^{32}$  personas aproximadamente)?
  - ¿Cómo hacemos los cálculos computacionalmente eficientes?



# Independencia: ¿Una Solución?

- **Independencia**

- Decimos que dos proposiciones  $A_1$  y  $A_2$  son **independientes** si el conocimiento de una no cambia la probabilidad de la otra
  - Por ejemplo si
    - $A_1$ ="Es rubio" ,  $A_2$ ="Tiene la piel clara" ,  $A_3$ ="Lloverá mañana"
    - $A_1$  y  $A_3$  son independientes  $A_1$  y  $A_2$  no.
- Formalmente  $A_1, A_2$  son independientes si  $P(A_1|A_2)=P(A_1)$   
o de forma equivalente:  $P(A_2|A_1)=P(A_2)$   
o utilizando la regla del producto  $P(A_1 \wedge A_2) = P(A_1) P(A_2)$
- Entonces  $P(A_1 \wedge A_2 \wedge \dots \wedge A_n) = P(A_1) P(A_2) \dots P(A_n)$   
Para especificar la distribución conjunta de  $n$  variables se necesitan  $O(n)$  números en lugar de  $O(2^n)$
- Dos **variables aleatorias son independientes** si el conocimiento del valor que toma una no cambia la probabilidad de los valores de la otra:  $P(A_1=c|A_2=d) = P(A_1=c)$

# Independencia Condicional

- **Pero...**

- La condición de independencia es muy restrictiva.
- Por ejemplo, los resultados de los tests en medicina no suelen ser independientes.

- **Independencia condicional**

- Se dice que dos proposiciones  $A_1, A_2$  son independientes dada una tercera  $B$  si cuando  $B$  está presente el conocimiento de una no influye en la probabilidad de la otra:  $P(A_1|A_2, B) = P(A_1|B)$   
o de forma equivalente:  $P(A_2|A_1, B) = P(A_2|B)$   
o de forma equivalente:  $P(A_1 \wedge A_2 | B) = P(A_1|B) P(A_2|B)$ 
  - Ejemplo:
    - $A_1$ ="Tengo congestión nasal"  $A_2$ ="Tengo fiebre"  $A_3$ ="Tengo gripe"
    - $A_1$  y  $A_2$  son dependientes pero son independientes si se conoce  $A_3$ .
- Ahora se tiene:  $P(A_1 \wedge A_2 \wedge \dots \wedge A_n | B) = P(A_1|B) P(A_2|B) \dots P(A_n|B)$ 
  - Tenemos  $o(n)$  números en lugar de  $o(2^n)$

# Independencia Condicional

- **Finalizamos el ejemplo:**

- ¿Y si hay varios tests  $B_1, B_2, \dots, B_m$ ?
- Como vimos, para calcular la probabilidad de que el paciente esté enfermo hay que calcular:

$$P(A | B_1, B_2, \dots, B_m) = P(B_1, B_2, \dots, B_m | A) P(A) / P(B_m, B_m, \dots, B_m)$$

- Si los tests  $B_1, B_2, \dots, B_m$  son independientes dada la enfermedad A (aproximación que suele dar buenos resultados):

$$P(B_1, B_2, \dots, B_m | A) = P(B_1 | A) P(B_2 | A) \dots P(B_m | A)$$

- El problema a resolver ya es **abordable**:

Basta calcular:

$$P(A | B_1, B_2, \dots, B_m) = P(B_1 | A) P(B_2 | A) \dots P(B_m | A) P(A) / P(B_m, B_m, \dots, B_m)$$

$$P(\neg A | B_1, B_2, \dots, B_m) = P(B_1 | \neg A) P(B_2 | \neg A) \dots P(B_m | \neg A) P(\neg A) / P(B_m, B_m, \dots, B_m)$$


$$\text{con } P(B_m, B_m, \dots, B_m) = P(B_1 | A) P(B_2 | A) \dots P(B_m | A) P(A) + P(B_1 | \neg A) P(B_2 | \neg A) \dots P(B_m | \neg A) P(\neg A)$$

# Representación de la Independencia: Redes Bayesianas

- **La clave hacer factible la inferencia con probabilidades es la introducción explícita de la independencia entre variables**
- **El modelo más extendido de representación de independencias lo constituye las **Redes Bayesianas**.**
- **En este modelo se representa de forma explícita la dependencia entre variables mediante un grafo**
- **Los nodos del grafo se corresponden con variables y las dependencias se representan mediante arcos entre ellas**

# Aplicación Regla de Bayes

- Ejemplo simple




Tenemos un conocimiento sobre la probabilidad de E ( $P(E)$ , **probabilidad a priori**). Indago y descubro que se da S. Conociendo  $P(S/E)$  y  $P(S/\neg E)$ , ¿qué probabilidad hay ahora ( $P(E/S)$  **probabilidad a posteriori**) de que se de E?

$$P(E|S) = \frac{P(S|E).P(E)}{P(S|E).P(E) + P(S|\neg E).P(\neg E)}$$

# Aplicación Regla de Bayes

- **Caso simple: Probabilidad inducida por un efecto**



Se conoce  $P(C)$ ,  $P(E|C)$  y  $P(E|\neg C)$ ,  
¿Puedo calcular  $P(C|E)$ ?

$$P(C|E) = \frac{P(E|C)*P(C)}{P(E|C)*P(C)+P(E|\neg C)*P(\neg C)}$$

# Aplicación Regla de Bayes

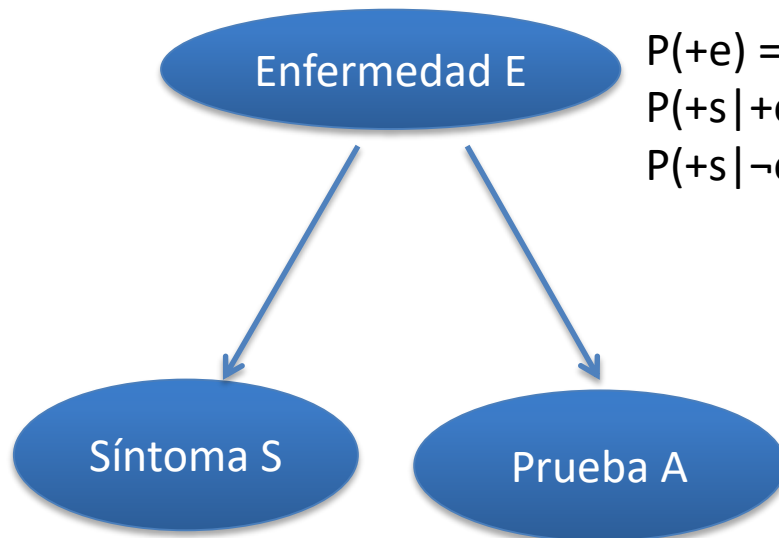
- Probabilidad inducida por varios efectos (**suponiendo independencia**)

ENFERMEDAD (E): presente (+e), ausente (-e)

SÍNTOMA (S): presente (+s), ausente (-s)

PRUEBA ANALÍTICA (A): positivo (+a), negativo (-a)

Grafo dirigido acíclico



$P(+e) = 0'002$  → probabilidad a priori

$P(+s|+e) = 0'93$   $P(+a|+e) = 0'995$  → prob de los efectos si +e

$P(+s|-e) = 0'01$   $P(+a|-e) = 0'003$  → prob de los efectos si -e

$P(+e|+s,+a) = P(+e,+s,+a) / P(+s,+a)$  ecuación cálculo

$P(+e,+s,+a) = P(+e).P(+s|+e).P(+a|+e) = 0,00185$

$P(-e,+s,+a) = P(-e).P(+s|-e).P(+a|-e) = 0,00003$

$P(+s,+a) = P(+e,+s,+a) + P(-e,+s,+a) = 0,00188$

$P(+e|+s,+a) = P(+e,+s,+a) / P(+s,+a) = 0,984$

# Red causal

- **Probabilidad inducida por varias factores (independientes) y varios efectos (independientes)**

Paludismo (X): presente  $+x$ , ausente  $-x$


Zona de origen (F1): alto riesgo  $f_1^+$ , riesgo medio  $f_1^0$ , riesgo bajo  $f_1^-$

Tipo sanguíneo (F2): mayor inmunidad  $f_2^+$ , menor inmunidad  $f_1^-$

Gota gruesa (E1): positivo  $e_1^+$ , negativo  $e_1^-$

Fiebre (E2): presente  $e_2^+$ , ausente  $e_2^-$

- **Grafo dirigido acíclico**





# Red Causal: conocimiento

Distribución de probabilidad de los factores

$$\begin{aligned} P(f_1+) &= 0,1 \\ P(f_1 0) &= 0,1 \\ P(f_1-) &= 0,8 \end{aligned}$$

$$\begin{aligned} P(f_2+) &= 0,6 \\ P(f_2-) &= 0,4 \end{aligned}$$

Distribución de probabilidad condicionada de la variable con respecto a los factores

$P(+x/f_1, f_2)$	$f_1+$	$f_1 0$	$f_1-$
$f_2+$	0,015	0,003	0,0003
$f_2-$	0,022	0,012	0,0008

Distribución de probabilidad condicionada de los efectos con respecto a la variable

$$\begin{aligned} P(+e_1 | +x) &= 0,992 \\ P(+e_2 | +x) &= 0,98 \end{aligned}$$

$$\begin{aligned} P(+e_1 | -x) &= 0,006 \\ P(+e_2 | -x) &= 0,017 \end{aligned}$$

# Red causal: Inferencia

$$P(f_1, f_2, x, e_1, e_2) = P(f_1) * P(f_2) * P(x | f_1, f_2) * P(e_1 | x) * P(e_2 | x)$$

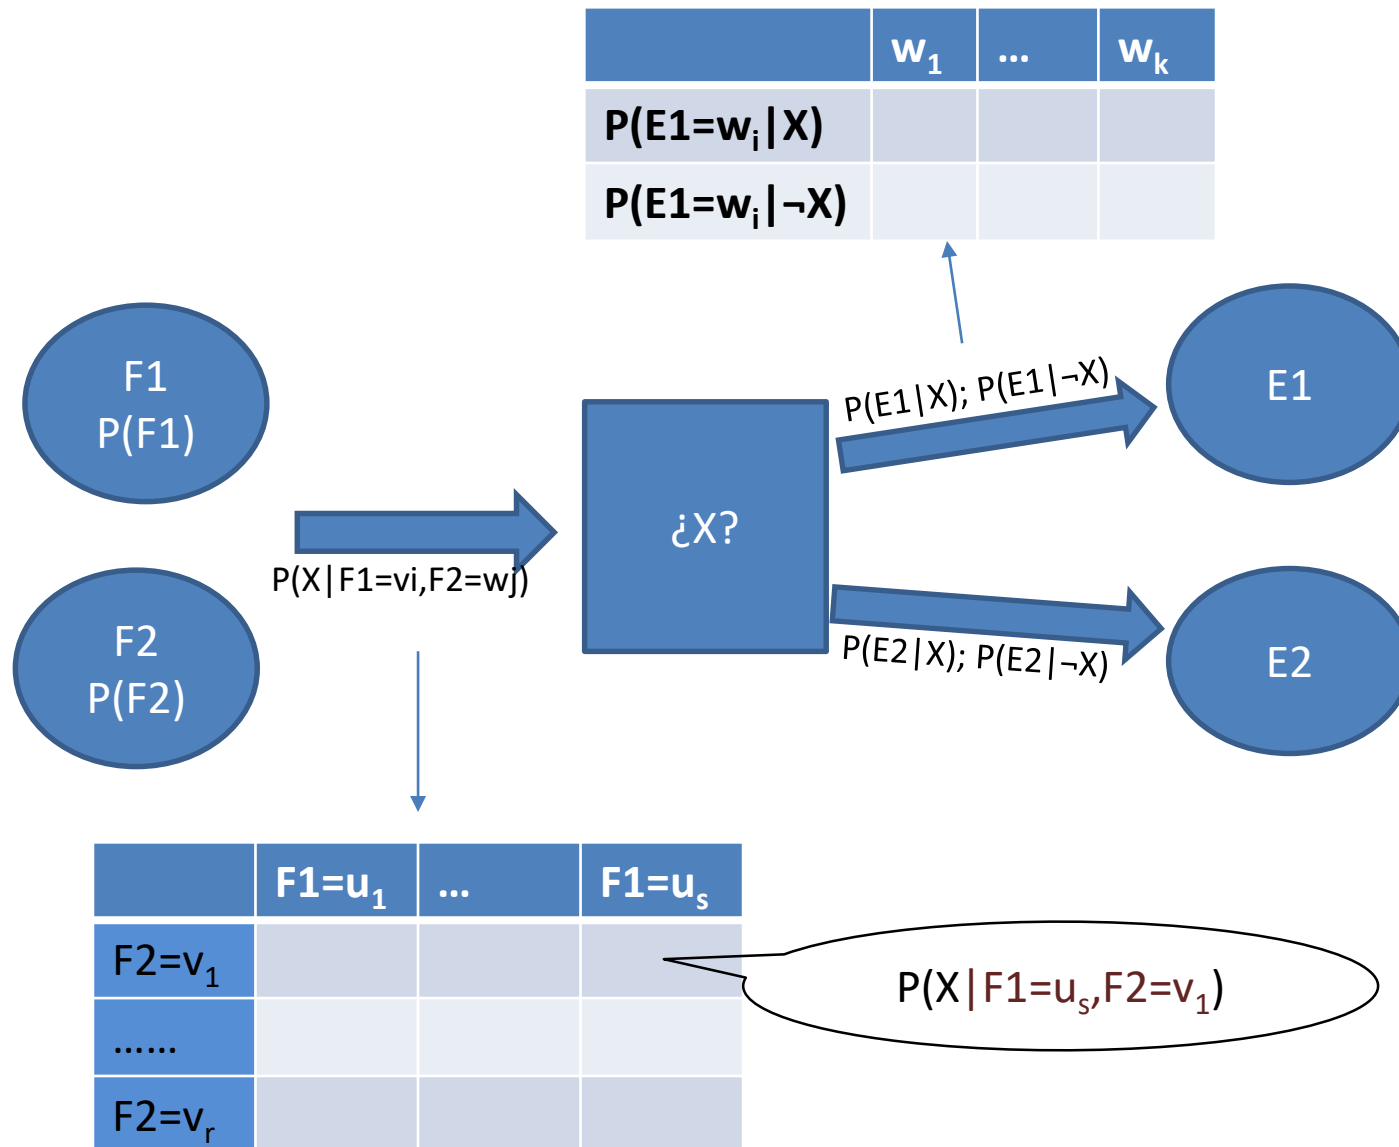
- Ejemplo: calcular  $P(+x | f_1^0, f_2^-, e_1^-, e_2^+)$ 
  - $P(f_1^0, f_2^-, +x, e_1^-, e_2^+) = P(f_1^0) * P(f_2^-) * P(+x | f_1^0, f_2^-) * P(e_1^- | +x) * P(e_2^+ | +x) =$   
 $= 0,1 * 0,4 * 0,012 * 0,008 * 0,98 = 0,00000376$
  - $P(f_1^0, f_2^-, -x, e_1^-, e_2^+) = P(f_1^0) * P(f_2^-) * P(-x | f_1^0, f_2^-) * P(e_1^- | -x) * P(e_2^+ | -x) =$   
 $= 0,1 * 0,4 * 0,988 * 0,994 * 0,017 = 0,00066780$
  - $P(f_1^0, f_2^-, e_1^-, e_2^+) = P(f_1^0, f_2^-, +x, e_1^-, e_2^+) + P(f_1^0, f_2^-, -x, e_1^-, e_2^+) = 0,00067156$
  - $P(+x | f_1^0, f_2^-, e_1^-, e_2^+) = P(f_1^0, f_2^-, +x, e_1^-, e_2^+) / P(f_1^0, f_2^-, e_1^-, e_2^+) =$   
 $= 0,00000376 / 0,00067156 = 0,0055989 \approx 0,0056$

# Red causal: deducciones

$P(+x, f_1, f_2)$	$f_1^+$	$f_1^0$	$f_1^-$				
$f_2^+$	0,0009	0,00018	0,000144	0,001224	$P(+x, f_2^+)$	0,00204	$P(+x   f_2^+)$
$f_2^-$	0,00088	0,00048	0,000256	0,001616	$P(+x, f_2^-)$	0,00404	$P(+x   f_2^-)$
	0,00178	0,00066	0,0004	0,00284	$P(+x)$		
	$P(+x, f_1^+)$	$P(+x, f_1^0)$	$P(+x, f_1^-)$				
	0,0178	0,0066	0,0005				
	$P(+x   f_1^+)$	$P(+x   f_1^0)$	$P(+x   f_1^-)$				

- **Probabilidad a priori:**  $P(+x) = 0,00284$
- **Probabilidad tras conocer los factores:**  $P(+x | f_1^0, f_2^-) = 0,012$   
 $P(+x | f_1^0) = 0,0066$  si desconozco el valor de F2  
 $P(+x | f_2^-) = 0,0040$  si desconozco el valor de F1
- **Probabilidad tras añadir conocimiento sobre los efectos:**  $P(+x | f_1^0, f_2^-, \neg e_1, e_2) = 0,0056$   
Si desconozco el valor de F1 y de E2, ¿ $P(+x | f_2^-, \neg e_1)$ ?

# En forma de SE (conocimiento)



# En forma de SE (inferencia)

- Probabilidad a priori

$$P(X \text{ a\_priori}) = P(X) = \sum P(X, F1 = ui, F2 = vj)$$

$$P(X, F1=u_i, F2=v_j) = P(F1=u_i) * P(F2=v_j) * P(X | F1=u_i, F2=v_j)$$

- Probabilidad a posteriori tras factores  $F1=u, F2=v$

$$P(X \text{ a\_posteriori\_factores}) = P(X | F1=u, F2=v)$$

- Probabilidad a posteriori tras factores y efectos  $E1=w, E2=z$

$$P(X \text{ a\_posteriori\_factores\_efectos}) = P(X | F1=u, F2=v, E1=w, E2=z)$$

$$C_x = P(F1=u) * P(F2=v) * P(X | F1=u, F2=v) * P(E1=w | X) * P(E2=z | X) = P(X, F1=u, F2=v, E1=w, E2=z)$$

$$C_{\neg x} = P(F1=u) * P(F2=v) * P(\neg X | F1=u, F2=v) * P(E1=w | \neg X) * P(E2=z | \neg X) = P(\neg X, F1=u, F2=v, E1=w, E2=z)$$

$$C = C_x + C_{\neg x} = P(F1=u, F2=v, E1=w, E2=z)$$

$$P(X \text{ a\_posteriori\_factores\_efectos}) = C_x / C$$

# Resumen de representaciones numéricas

- **Grados de certidumbre en Mycin**

- Asigna: Un número entre -1 y 1 a cada regla
- Mide: La incertidumbre asociada a cada regla
- Aplicaciones: Sistemas Expertos
- Ventajas: El número de parámetros necesario es razonable
- Inconvenientes: Débil representación de la independencia, Incoherencias

- **Lógica difusa**

- Asigna: Un número entre 0 y 1 a cada proposición
- Mide: La verdad asociada a cada proposición
- Aplicaciones: Sistemas Expertos, Control
- Ventajas: Proporciona una forma de razonar con la vaguedad asociadas al lenguaje natural
- Inconvenientes: Tiene muchas elecciones arbitrarias (combinación de grados de creencia, inferencia, etc.)

# Resumen de representaciones numéricas

- **Probabilidad**

- Asigna: Un número entre 0 y 1 a cada proposición
- Mide: La incertidumbre asociada a dicha proposición
- Aplicaciones: Sistemas Expertos, Clasificación
- Ventajas: Sistema formalmente probado y robusto
- Inconvenientes: Se necesita mucha información

# IMPRECISIÓN EN LAS AFIRMACIONES VS IMPRECISIÓN EN EL CONOCIMIENTO DE LA VERACIDAD

Conocimiento verdad Afirmaciones	PRECISO	IMPRECISO: RETRACTABLE	IMPRECISO: BASADA EN ESTADISTICA	IMPRECISO: BASADO EN CREENCIAS
PRECISAS	LÓGICA CLASICA	- LÓGICA POR DEFECTO - HIPOTESIS DEL MUNDO CERRADO	PROBABILIDAD	FACTORES DE CERTeza
IMPRECISAS	LÓGICA DIFUSA	LÓGICA DIFUSA POR DEFECTO	LÓGICA DIFUSA PROBABILISTICA	LÓGICA DIFUSA CON FACTORES DE CERTeza